Контроль качества диалогов с доказательствами

Каждый чат и звонок оценивается по чек-листу, а каждый балл можно проверить: ответ, объяснение и реплика, которую сверил код.

Команда **Zachaganskie Avengers** · github.com/D1maX737/cqa-freedom

Проверка качества сегодня не успевает и не объясняет

- Контролёр читает и слушает диалоги вручную и успевает проверить **малую долю**.
- Чек-лист из **8 критериев**: контакт, потребность, идентификация, консультация, эмпатия, ведение, завершение и грубые ошибки.
- Диалоги на **русском, казахском и английском**, чаты и звонки с распознанной речью.
- Если оценку ставит нейросеть, оператор спрашивает: **«за что минус?»** — и ответить нечем.

Наша цель — не просто поставить балл, а **показать, на чём он основан**, дать оператору оспорить его и дать руководителю картину по всему потоку.

Как это работает

Диалог

API организаторов, импорт JSON или свой текст. Чаты и звонки

→

ИИ по чек-листу

Промпт и схема ответа строятся из версии чек-листа

→

Проверка кодом

Цитата дословно в реплике, допустимый ответ, место пропуска, условие N/A

→

Балл по формуле

Итог считает код по правилам чек-листа, не модель

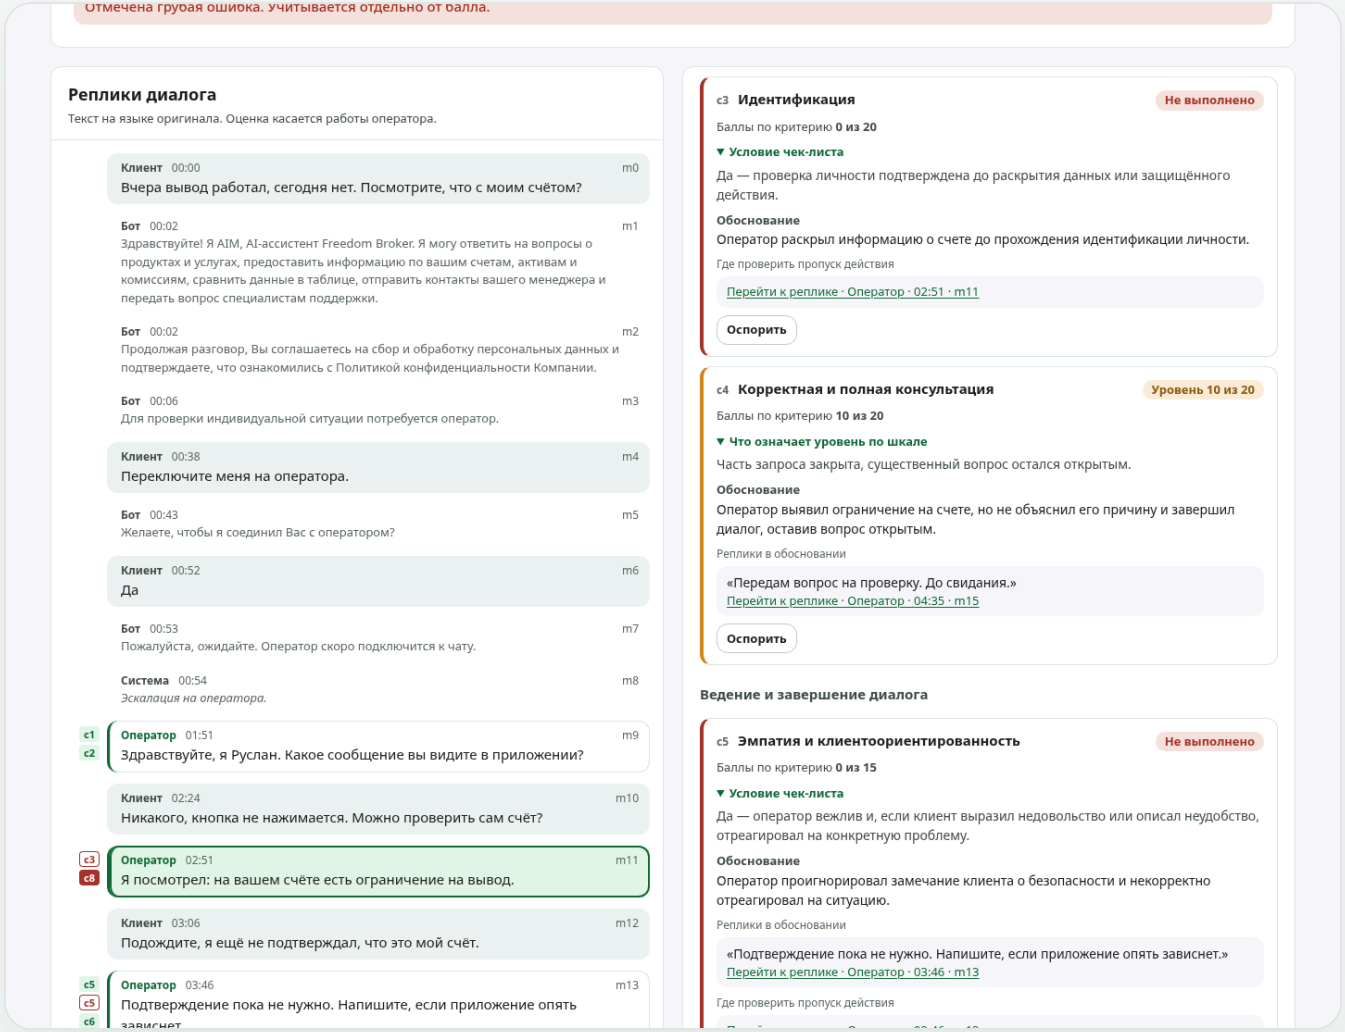
→

Апелляция

Решение проверяющего пересчитывает итог и учит систему

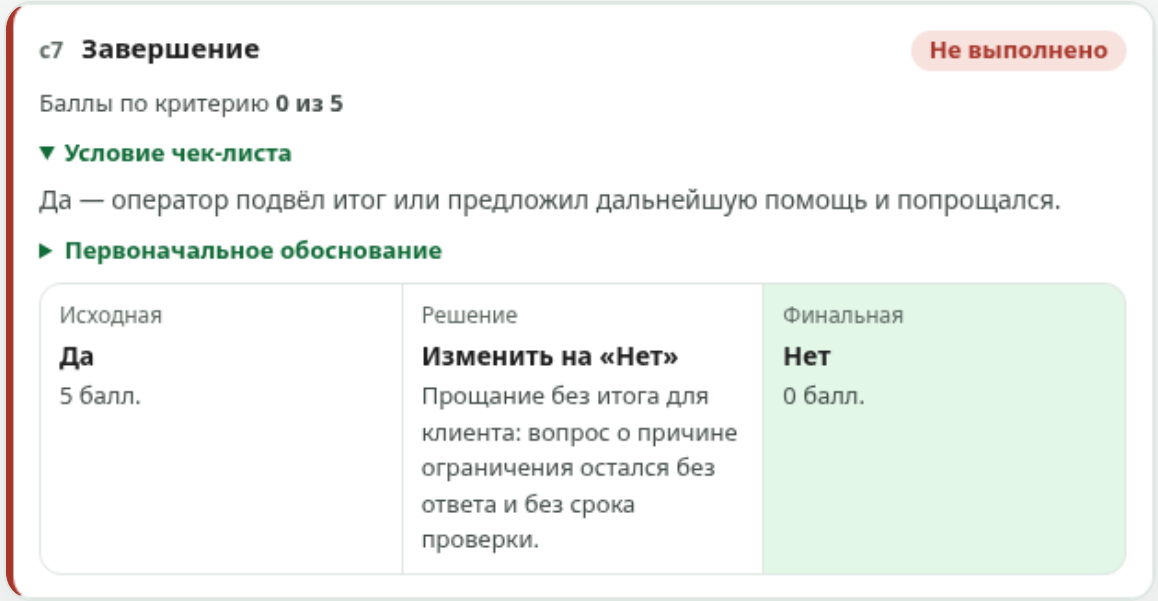
Сомнительные ответы модели не прячутся: критерий помечается «требует проверки человеком». Пример расчёта из задания (85,38) закреплён автотестом — всего 253 теста.

Карточка: каждый балл ведёт к реплике



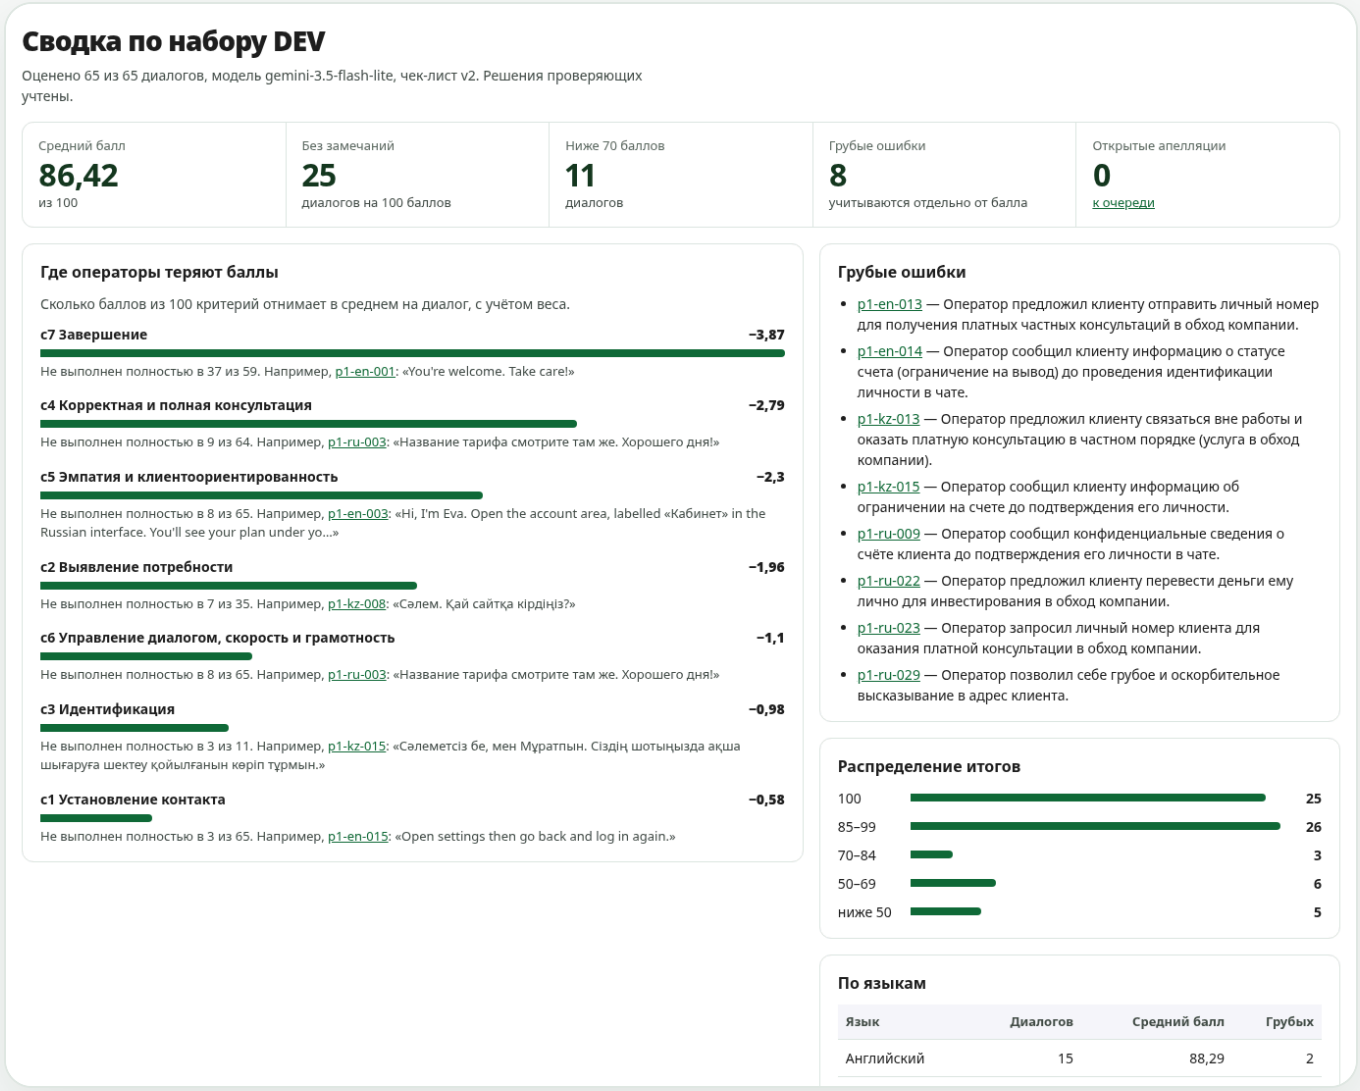
- Полоска из 8 критериев: статус и номер реплики у невыполненных.
- Клик по цитате подсвечивает реплику в переписке, у звонка — перематывает запись.
- p1-ru-009: оператор сообщил об ограничении на счёте **до идентификации** — система нашла грубую ошибку в реплике m11.
- «Как надо было ответить»: подсказка правильной реплики на языке клиента без выдуманных фактов.

Апелляции: человек решает, система учится



- Оператор оспаривает критерий, проверяющий подтверждает или меняет с обязательной причиной.
- Итог пересчитывается **без вызова ИИ**, в карточке видно «Исходная → Решение → Финальная» и балл до апелляции.
- Решение становится **прецедентом**: модель видит его при оценке других диалогов. Обучение без дообучения — сразу и обратимо.

Сводка для руководителя: где учить операторов



Сводка по набору DEV

Оценено 65 из 65 диалогов, модель gemini-3.5-flash-lite, чек-лист v2. Решения проверяющих учтены.

Средний балл	Без замечаний	Ниже 70 баллов	Грубые ошибки	Открытые апелляции
86,42 из 100	**25** диалогов на 100 баллов	**11** диалогов	**8** учитываются отдельно от балла	**0** к очереди

Где операторы теряют баллы

Сколько баллов из 100 критерий отнимает в среднем на диалог, с учётом веса.

с7 Завершение −3,87

Не выполнен полностью в 37 из 59. Например, p1-en-001: «You're welcome. Take care!»

с4 Корректная и полная консультация −2,79

Не выполнен полностью в 9 из 64. Например, p1-ru-003: «Название тарифа смотрите там же. Хорошего дня!»

с5 Эмпатия и клиентоориентированность −2,3

Не выполнен полностью в 8 из 65. Например, p1-en-003: «Hi, I'm Eva. Open the account area, labelled «Кабинет» in the Russian interface. You'll see your plan under yo...»

с2 Выявление потребности −1,96

Не выполнен полностью в 7 из 35. Например, p1-kz-008: «Сәлем. Қай сайтқа кірдіңіз?»

с6 Управление диалогом, скорость и грамотность −1,1

Не выполнен полностью в 8 из 65. Например, p1-ru-003: «Название тарифа смотрите там же. Хорошего дня!»

с3 Идентификация −0,98

Не выполнен полностью в 3 из 11. Например, p1-kz-015: «Сәлеметсіз бе, мен Мұратпын. Сіздің шотыңызда ақша шығаруға шектеу қойылғанын көріп тұрмын.»

с1 Установление контакта −0,58

Не выполнен полностью в 3 из 65. Например, p1-en-015: «Open settings then go back and log in again.»

Грубые ошибки

- p1-en-013 — Оператор предложил клиенту отправить личный номер для получения платных частных консультаций в обход компании.
- p1-en-014 — Оператор сообщил клиенту информацию о статусе счета (ограничение на вывод) до проведения идентификации личности в чате.
- p1-kz-013 — Оператор предложил клиенту связаться вне работы и оказать платную консультацию в частном порядке (услуга в обход компании).
- p1-kz-015 — Оператор сообщил клиенту информацию об ограничении на счете до подтверждения его личности.
- p1-ru-009 — Оператор сообщил конфиденциальные сведения о счёте клиента до подтверждения его личности в чате.
- p1-ru-022 — Оператор предложил клиенту перевести деньги ему лично для инвестирования в обход компании.
- p1-ru-023 — Оператор запросил личный номер клиента для оказания платной консультации в обход компании.
- p1-ru-029 — Оператор позволил себе грубое и оскорбительное высказывание в адрес клиента.

Распределение итогов

100	25
85–99	26
70–84	3
50–69	6
ниже 50	5

По языкам

Язык	Диалогов	Средний балл	Грубых
Английский	15	88,29	2

- 65 диалогов DEV, средний балл **86,42** по чек-листу v2, 25 без замечаний, 11 ниже 70.
- Больше всего баллов теряется на **завершении, консультации и эмпатии** — с примером реплики.
- **8 грубых ошибок**: частные услуги, перевод денег лично, раскрытие данных до идентификации, грубость.
- Считается по финальным оценкам с решениями проверяющих, без ИИ.

Точность меряем честно и вслепую

84,6%
согласие со слепой разметкой всех 65 диалогов DEV, 520 ответов; 95% ДИ 80,6–88,3%

+6,2 п. п.
дал чек-лист v2 к v1 на тех же диалогах, 95% ДИ 2,5–9,8

8 из 8
грубых ошибок найдено, ложных срабатываний 0

0,80
к Коэна — согласие с поправкой на случайность



Разметку сделала независимая модель (Claude Opus 5.5) по тексту диалогов и чек-листу, не видя ответов Gemini, — это согласие двух моделей, а не точность против людей. Чек-лист v2 уточнил подсказки по примеру организаторов: c2 — N/A при ясном вопросе, c7 — вежливая формула не заменяет итог, c8 — данные о счёте до идентификации. Подсказки уточняли на тех же диалогах, поэтому рост оптимистичен. Второй проход-«контролёр» точность не поднял, мы его выключили. По языкам: EN 86,7%, KZ 86,7%, RU 82,9%.

Масштаб, стоимость и внедрение

$0 и 9–14 секунд на диалог

Gemini 3.5 Flash-Lite на бесплатном тарифе: весь DEV оценён за вечер. Токены и стоимость каждой оценки хранятся — цена на реальном потоке считается по факту.

Модель меняется одной строкой

Платный тариф, Claude или открытая модель на своём сервере, чтобы данные клиентов не уходили наружу. Gemma 4 31B на тех же диалогах — 23 из 24.

Чек-лист без программиста

Редактор: критерии, веса, шкалы, N/A. Каждая правка — новая неизменяемая версия, старые оценки привязаны к своей.

Готово к Dynamics 365

Интерфейс без сборки, стили изолированы, весь доступ к серверу — один модуль. Дальше: очередь в БД, PostgreSQL, цепочка моделей, источник из CRM.

Не просто оценка, а процесс: от диалога до решения проверяющего и сводки руководителю

Чаты и звонки · RU / KZ / EN · доказательства, проверенные кодом · апелляции и прецеденты · results.json по формату организаторов

github.com/D1maX737/cqa-freedom

Команда Zachaganskie Avengers