Контроль качества диалогов с доказательствами

Каждый чат и звонок оценивается по чек-листу, а каждый балл можно проверить: ответ, объяснение и реплика, которую сверил код.

Команда **Zachaganskie Avengers** · github.com/D1maX737/cqa-freedom

Проверка качества сегодня не успевает и не объясняет

- Контролёр читает и слушает диалоги вручную и успевает проверить **малую долю**.
- Чек-лист из **8 критериев**: контакт, потребность, идентификация, консультация, эмпатия, ведение, завершение и грубые ошибки.
- Диалоги на **русском, казахском и английском**, чаты и звонки с распознанной речью.
- Если оценку ставит нейросеть, оператор спрашивает: **«за что минус?»** — и ответить нечем.

Наша цель — не просто поставить балл, а **показать, на чём он основан**, дать оператору оспорить его и дать руководителю картину по всему потоку.

Как это работает

Диалог

API организаторов, импорт JSON или свой текст. Чаты и звонки

→

ИИ по чек-листу

Промпт и схема ответа строятся из версии чек-листа

→

Проверка кодом

Цитата дословно в реплике, допустимый ответ, место пропуска, условие N/A

→

Балл по формуле

Итог считает код по правилам чек-листа, не модель

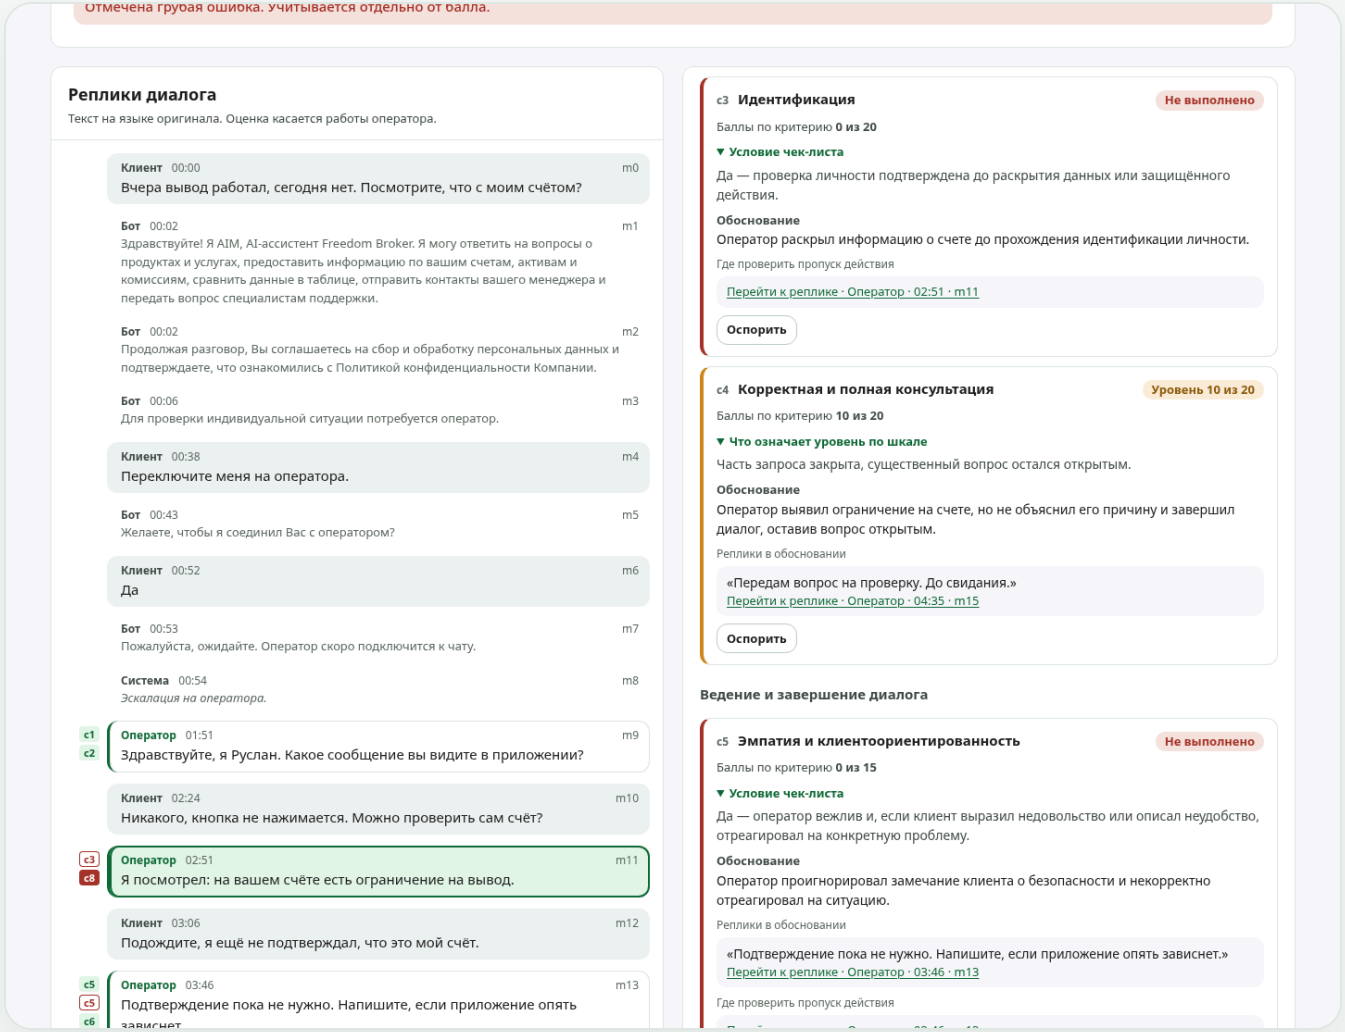
→

Апелляция

Решение проверяющего пересчитывает итог и учит систему

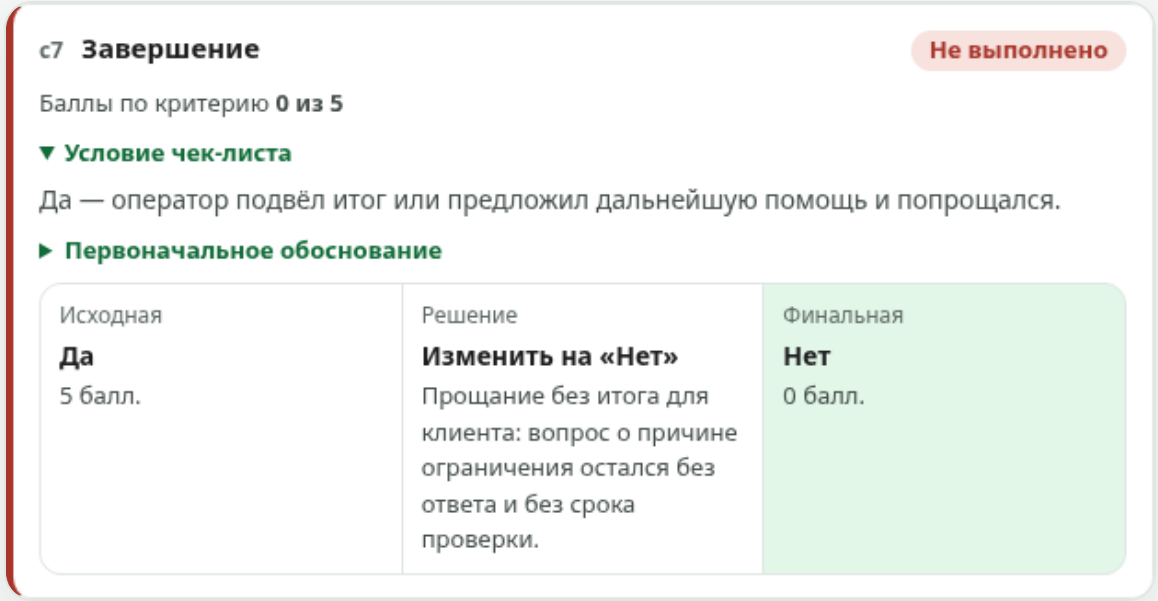
Сомнительные ответы модели не прячутся: критерий помечается «требует проверки человеком». Пример расчёта из задания (85,38) закреплён автотестом — всего 251 тест.

Карточка: каждый балл ведёт к реплике



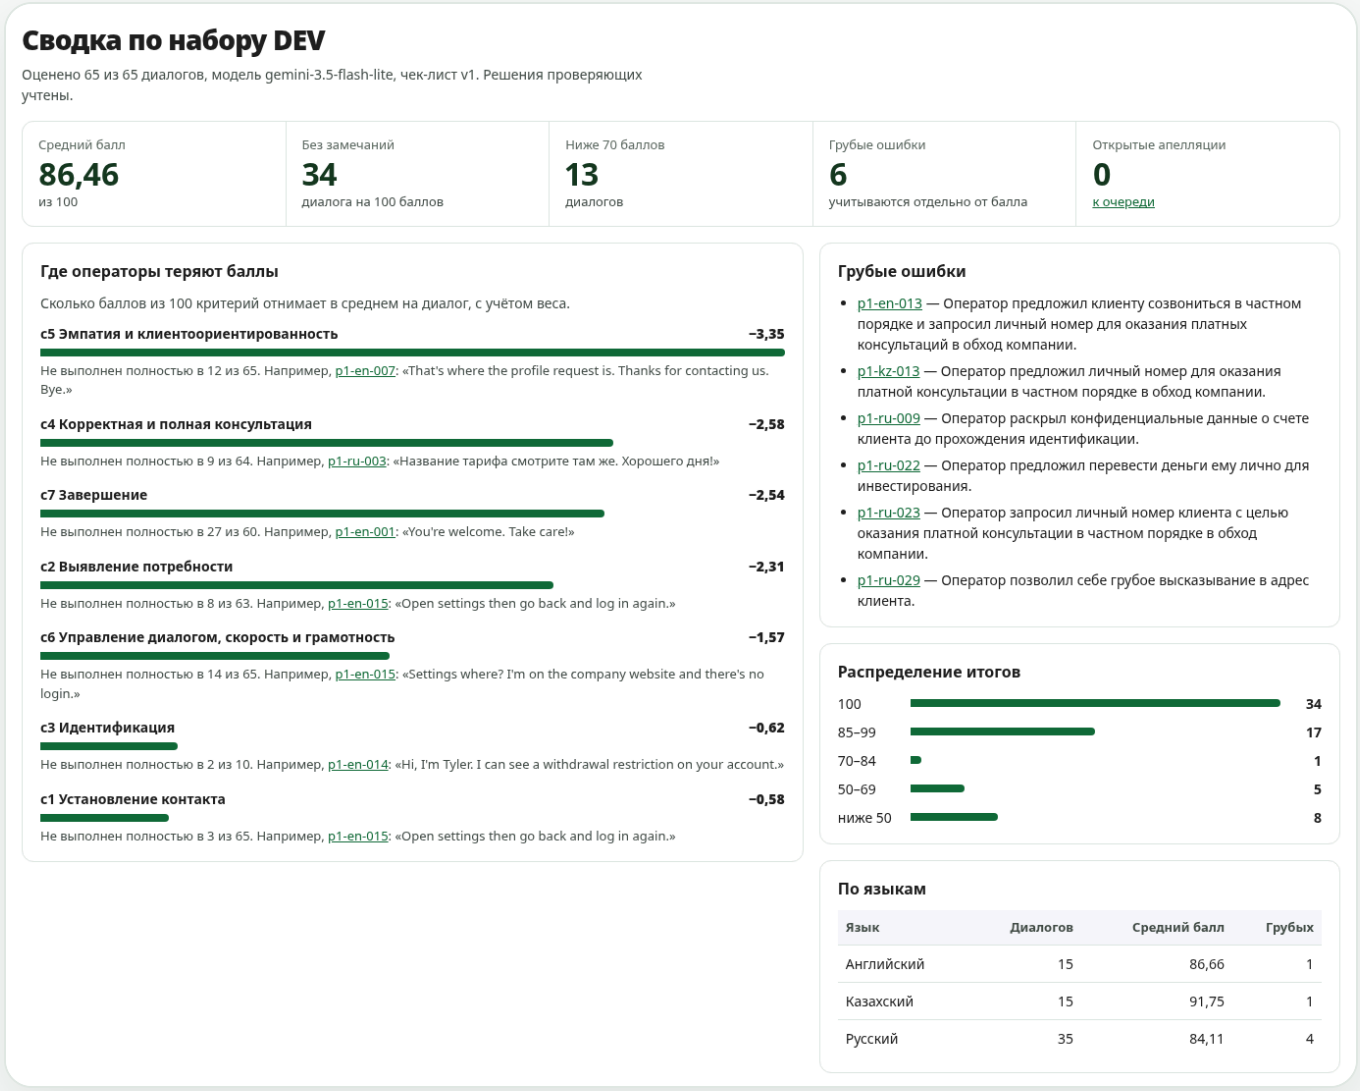
- Полоска из 8 критериев: статус и номер реплики у невыполненных.
- Клик по цитате подсвечивает реплику в переписке, у звонка — перематывает запись.
- p1-ru-009: оператор сообщил об ограничении на счёте **до идентификации** — система нашла грубую ошибку в реплике m11.
- «Как надо было ответить»: подсказка правильной реплики на языке клиента без выдуманных фактов.

Апелляции: человек решает, система учится



- Оператор оспаривает критерий, проверяющий подтверждает или меняет с обязательной причиной.
- Итог пересчитывается **без вызова ИИ**, в карточке видно «Исходная → Решение → Финальная» и балл до апелляции.
- Решение становится **прецедентом**: модель видит его при оценке других диалогов. Обучение без дообучения — сразу и обратимо.

Сводка для руководителя: где учить операторов



Сводка по набору DEV

Оценено 65 из 65 диалогов, модель gemini-3.5-flash-lite, чек-лист v1. Решения проверяющих учтены.

Средний балл	Без замечаний	Ниже 70 баллов	Грубые ошибки	Открытые апелляции
86,46 из 100	**34** диалога на 100 баллов	**13** диалогов	**6** учитываются отдельно от балла	**0** к очереди

Где операторы теряют баллы

Сколько баллов из 100 критерий отнимает в среднем на диалог, с учётом веса.

c5 Эмпатия и клиентоориентированность −3,35

Не выполнен полностью в 12 из 65. Например, p1-en-007: «That's where the profile request is. Thanks for contacting us. Bye.»

c4 Корректная и полная консультация −2,58

Не выполнен полностью в 9 из 64. Например, p1-ru-003: «Название тарифа смотрите там же. Хорошего дня!»

c7 Завершение −2,54

Не выполнен полностью в 27 из 60. Например, p1-en-001: «You're welcome. Take care!»

c2 Выявление потребности −2,31

Не выполнен полностью в 8 из 63. Например, p1-en-015: «Open settings then go back and log in again.»

c6 Управление диалогом, скорость и грамотность −1,57

Не выполнен полностью в 14 из 65. Например, p1-en-015: «Settings where? I'm on the company website and there's no login.»

c3 Идентификация −0,62

Не выполнен полностью в 2 из 10. Например, p1-en-014: «Hi, I'm Tyler. I can see a withdrawal restriction on your account.»

c1 Установление контакта −0,58

Не выполнен полностью в 3 из 65. Например, p1-en-015: «Open settings then go back and log in again.»

Грубые ошибки

- p1-en-013 — Оператор предложил клиенту созвониться в частном порядке и запросил личный номер для оказания платных консультаций в обход компании.
- p1-kz-013 — Оператор предложил личный номер для оказания платной консультации в частном порядке в обход компании.
- p1-ru-009 — Оператор раскрыл конфиденциальные данные о счете клиента до прохождения идентификации.
- p1-ru-022 — Оператор предложил перевести деньги ему лично для инвестирования.
- p1-ru-023 — Оператор запросил личный номер клиента с целью оказания платной консультации в частном порядке в обход компании.
- p1-ru-029 — Оператор позволил себе грубое высказывание в адрес клиента.

Распределение итогов

100	34
85–99	17
70–84	1
50–69	5
ниже 50	8

По языкам

Язык	Диалогов	Средний балл	Грубых
Английский	15	86,66	1
Казахский	15	91,75	1
Русский	35	84,11	4

- 65 диалогов DEV, средний балл **86,46**, 34 без замечаний, 13 ниже 70.
- Больше всего баллов теряется на **эмпатии, консультации и завершении** — с примером реплики.
- **6 грубых ошибок**: частные услуги, перевод денег лично, раскрытие данных, грубость.
- Считается по финальным оценкам с решениями проверяющих, без ИИ.

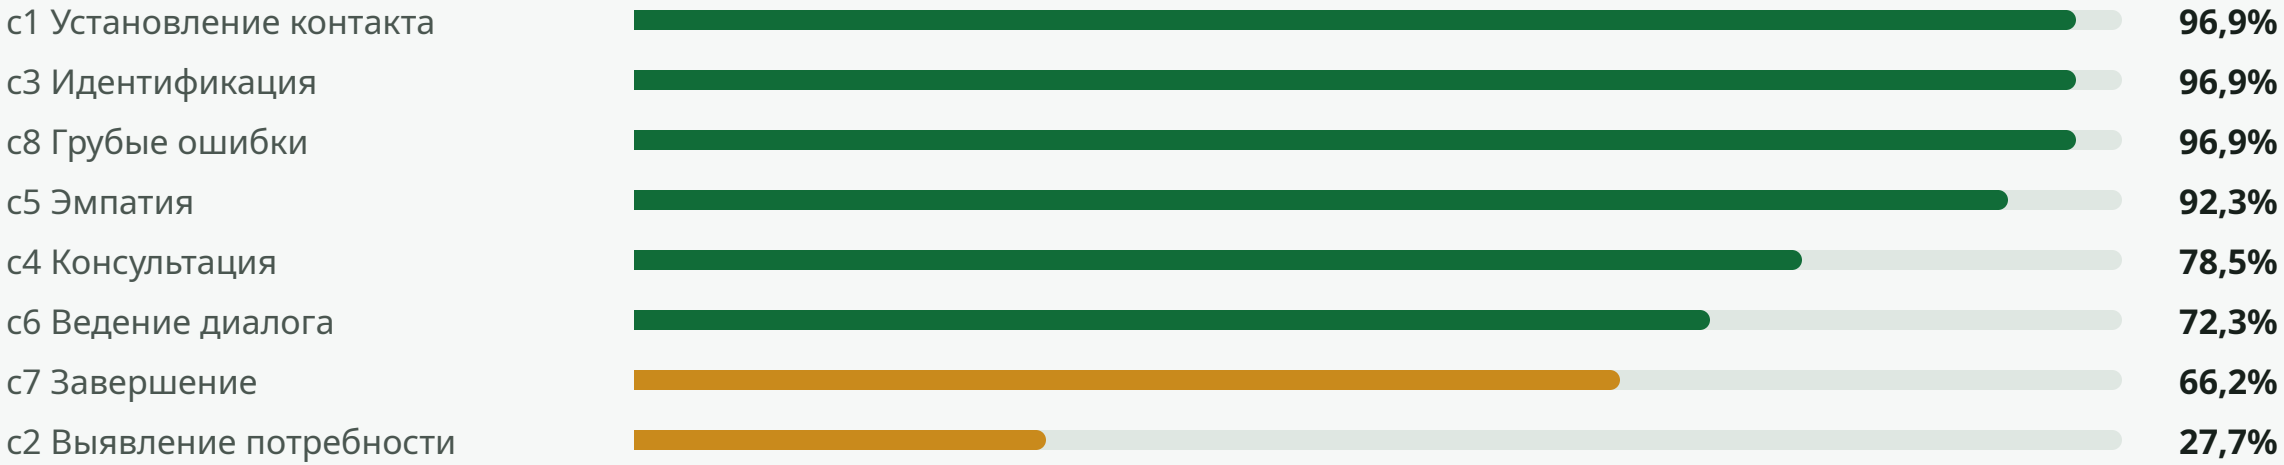
Точность меряем честно и вслепую

78,5%
согласие со слепой разметкой всех 65 диалогов DEV, 520 ответов

0,72
к Коэна — согласие с поправкой на случайность

6 из 8
грубых ошибок найдено, ложных срабатываний 0

6
моделей сравнили на одних диалогах, включая локальные и казахскую KazLLM



Разметку сделала независимая модель (Claude Opus 5.5) по тексту диалогов и чек-листу, не видя ответов Gemini, — это согласие двух моделей, а не точность против людей. Главное расхождение c2: при ясном вопросе клиента пример организаторов ставит N/A, а модель «Да» — это следующее исправление в чек-листе. Второй проход-«контролёр» точность не поднял, и мы его выключили. По языкам: EN 79%, KZ 78%, RU 79%.

Масштаб, стоимость и внедрение

$0 и 9–14 секунд на диалог

Gemini 3.5 Flash-Lite на бесплатном тарифе: весь DEV оценён за вечер. Токены и стоимость каждой оценки хранятся — цена на реальном потоке считается по факту.

Модель меняется одной строкой

Платный тариф, Claude или открытая модель на своём сервере, чтобы данные клиентов не уходили наружу. Gemma 4 31B на тех же диалогах — 23 из 24.

Чек-лист без программиста

Редактор: критерии, веса, шкалы, N/A. Каждая правка — новая неизменяемая версия, старые оценки привязаны к своей.

Готово к Dynamics 365

Интерфейс без сборки, стили изолированы, весь доступ к серверу — один модуль. Дальше: очередь в БД, PostgreSQL, цепочка моделей, источник из CRM.

Не просто оценка, а процесс: от диалога до решения проверяющего и сводки руководителю

Чаты и звонки · RU / KZ / EN · доказательства, проверенные кодом · апелляции и прецеденты · results.json по формату организаторов

github.com/D1maX737/cqa-freedom

Команда Zachaganskie Avengers